

RAPPORT DE PROJET

Master Informatique - SAS

TP 3 : iLinkMortgage

SAS Viya pour la modélisation du risque de crédit immobilier

Réalisé par : Mathura SANTHALINGAM

Encadrant : M. DE LASSENCE

Sommaire

Task 1: Examining Alex's Work in SAS Studio 3

Task 2: Managing your Analysis with Flows in SAS Studio 3

Task 2a: Refining Your Modeling with SAS Viya Copilot 5

Task 3: SAS Visual Analytics – A No-Code Paradise 5

Task 3a: Using SAS Viya Copilot to Improve your Visual Analytics Project 7

Task 4: Going Deeper with SAS Model Studio 9

Task 4a: Using Copilot to Improve and Interpret your SAS Model 13

Task 5: Adding Ethical Data Analysis to your SAS Model Studio Project 15

Task 6: Reviewing the Champion Model with SAS Model Manager 17

Task 7: Scoring New Loan Applications with SAS Intelligent Decisioning 18

Task 8: Return to SAS Visual Analytics to Review New Loan Decisions 20

Task 1: Examining Alex's Work in SAS Studio

Tests d'ajustement					
Nombre d'observations	Erreur quadratique			Erreur conséquentielle de la moyenne	Perte log. multiclasse
	Diviseur de la moyenne	Moyenne	RASE		
1788	1788	0.085422	0.292270	0.111298	0.283468

Les performances de validation changent un peu en raison de la **variabilité d'échantillonnage**. Comme aucune grain n'a été fixée lors de la création des modèles, la répartition aléatoire des données entre les échantillons d'entraînement, de validation et de test varie d'un participant à l'autre, ce qui empêche une reproductibilité parfaite.

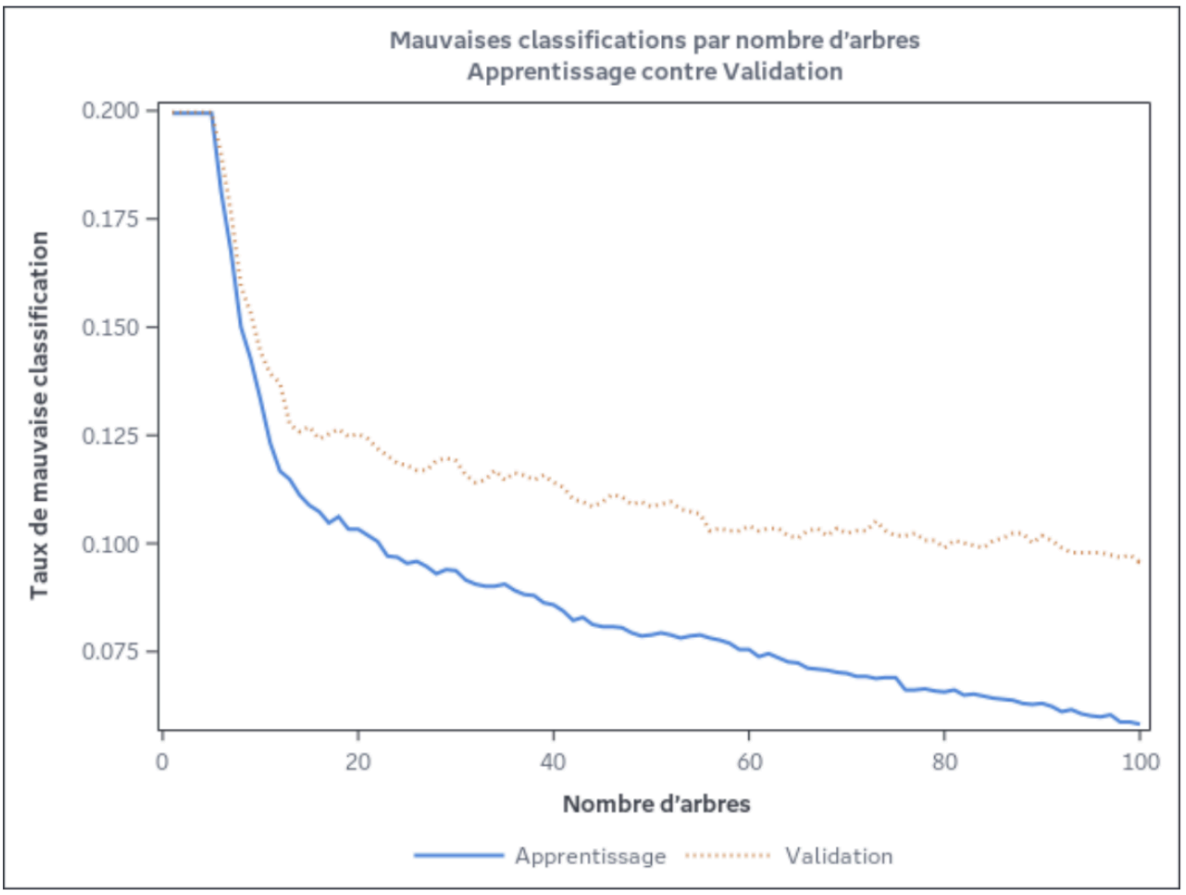
Tests d'ajustement					
Nombre d'observations	Erreur quadratique			Erreur conséquentielle de la moyenne	Perte log. multiclasse
	Diviseur de la moyenne	Moyenne	RASE		
1788	1788	0.103475	0.321675	0.137584	0.334217

Comme le dit le tutoriel, cette augmentation démontre qu'ajuster la taille minimale des feuilles à 50 (minleafsize=50) n'améliore pas l'ajustement du modèle dans ce scénario.

```
NOTE: Cloud Analytic Services promoted table _PREPPED in caslib CASUSER(mathura.santhalingam@edu.univ-paris13.fr) to table _prepped
      in caslib CASUSER(mathura.santhalingam@edu.univ-paris13.fr).
NOTE: The Cloud Analytic Services server processed the request in 0.002152 seconds.
```

Ce message du journal (Log) confirme que la table _PREPPED a bien été promue et qu'elle est désormais accessible globalement.

Task 2: Managing your Analysis with Flows in SAS Studio



Ce graphique compare l'évolution du taux d'erreur entre les données d'apprentissage (ligne bleue) et de validation (ligne orange) en fonction du nombre d'arbres du modèle.

- L'erreur d'apprentissage diminue de manière continue pour atteindre environ 0,06 à 100 arbres.
- L'erreur de validation diminue rapidement au début puis stagne pour former un plateau autour de 0,10 à partir d'une trentaine d'arbres.
- L'écart de plus en plus large entre les deux courbes montre que l'ajout d'arbres n'améliore plus la capacité de généralisation du modèle et indique un surapprentissage modéré : l'erreur de validation stagne mais ne remonte pas sur les données d'entraînement.

Tests d'ajustement						
Nombre d'arbres	Erreur quadratique moyenne de l'apprentissage	Erreur quadratique moyenne de validation	Taux de mauvaise classification de l'apprentissage	Taux de mauvaise classification de validation	Log. de la fonction de perte d'apprentissage	Log. de la fonction de perte de validation
1	0.1474	0.1486	0.1994	0.1997	0.464	0.467
2	0.1373	0.1401	0.1994	0.1997	0.436	0.444
3	0.1287	0.1326	0.1994	0.1997	0.413	0.424
4	0.1219	0.1268	0.1994	0.1997	0.396	0.409
5	0.1162	0.1224	0.1994	0.1997	0.381	0.397
6	0.1116	0.1182	0.1810	0.1896	0.369	0.386
7	0.1074	0.1142	0.1673	0.1762	0.358	0.376
8	0.1033	0.1105	0.1500	0.1594	0.347	0.366
9	0.1001	0.1080	0.1426	0.1532	0.338	0.359
10	0.0974	0.1057	0.1333	0.1443	0.330	0.353
11	0.0950	0.1041	0.1232	0.1393	0.323	0.348
12	0.0932	0.1024	0.1167	0.1370	0.317	0.343
13	0.0915	0.1009	0.1148	0.1275	0.312	0.339
14	0.0897	0.0993	0.1112	0.1258	0.307	0.334
15	0.0882	0.0983	0.1088	0.1270	0.302	0.331
16	0.0866	0.0969	0.1074	0.1242	0.298	0.327
17	0.0853	0.0959	0.1047	0.1253	0.294	0.324
18	0.0841	0.0950	0.1062	0.1264	0.290	0.321
19	0.0829	0.0941	0.1033	0.1247	0.286	0.318
20	0.0818	0.0929	0.1033	0.1253	0.283	0.314

Which approach would you assign in an introductory course?

L'approche visuelle et sans code est privilégiée car elle permet aux débutants de comprendre la structure globale d'un pipeline analytique et de se concentrer sur l'interprétation des modèles sans être freinés par la syntaxe de programmation.

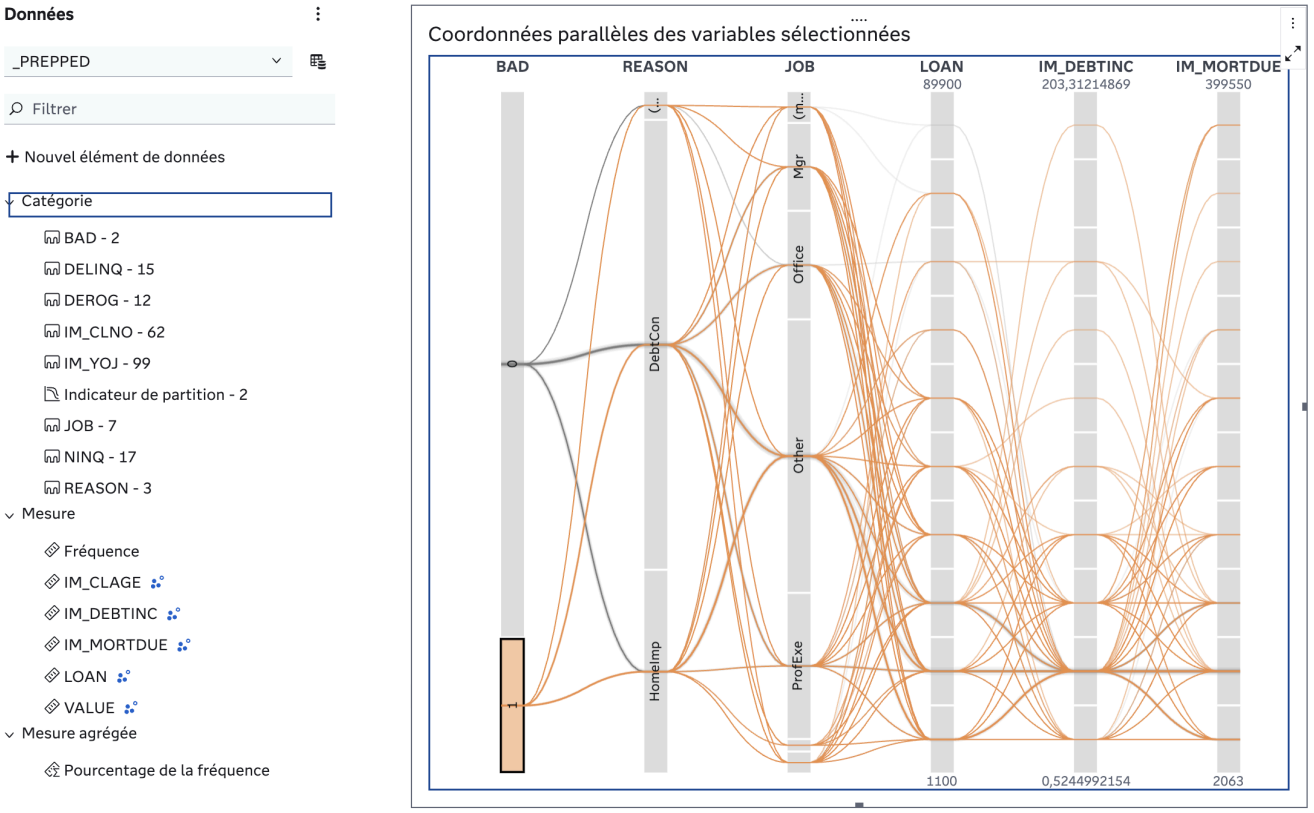
Which would you use in a production environment?

L'approche par le code ou via des flux est privilégiée car cette méthode garantit la reproductibilité, l'automatisation, la documentation des processus et facilite le partage et l'audit par les équipes, des éléments indispensables pour un déploiement à l'échelle de l'entreprise.

Task 2a: Refining Your Modeling with SAS Viya Copilot

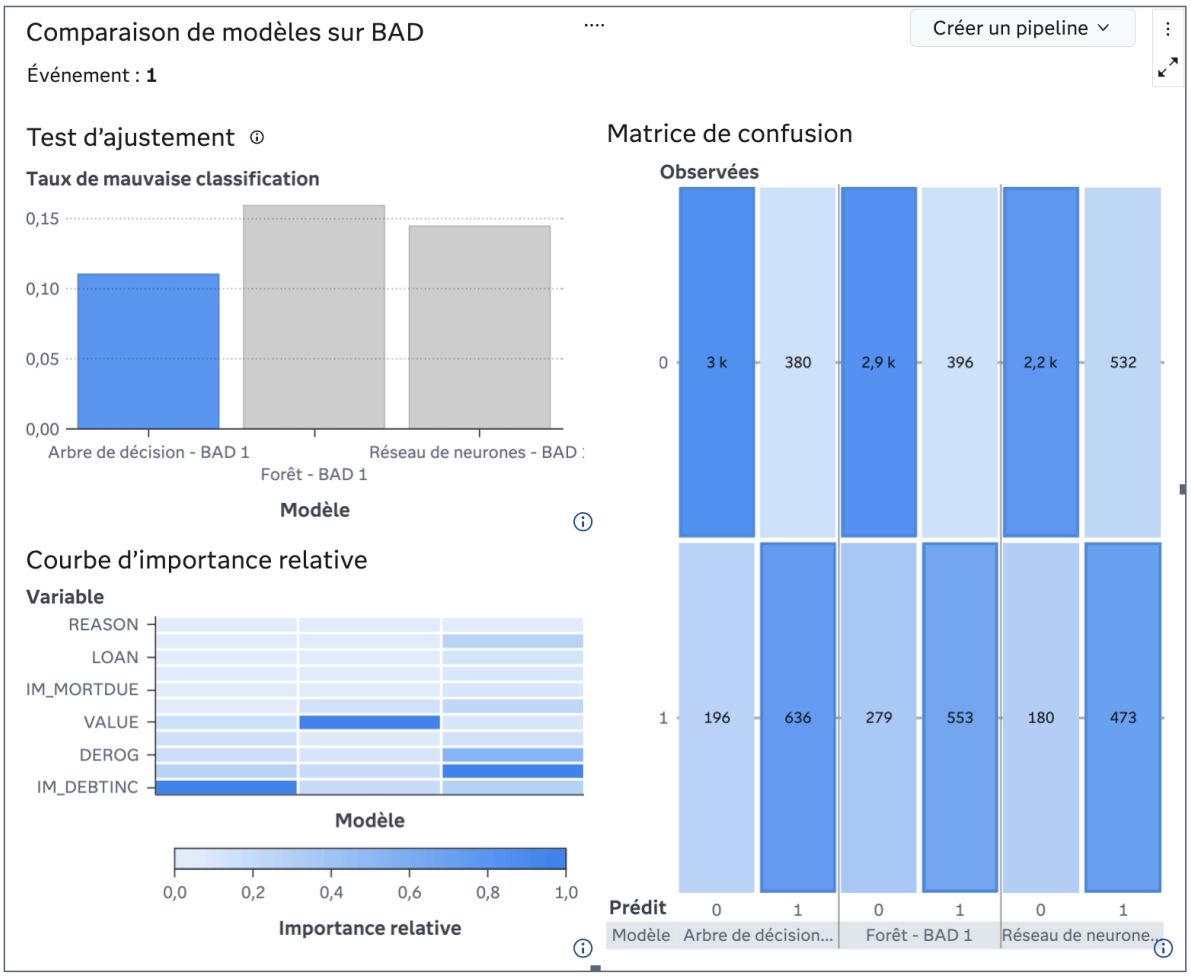
Il m'était impossible de le faire.

Task 3: SAS Visual Analytics – A No-Code Paradise



Les lignes orange (BAD=1) sont nombreuses dans les tranches basses de LOAN, IM_DEBTINC et IM_MORTDUE. Cela peut refléter la distribution générale de ces variables, et pas un effet propre aux défauts.

La majorité des défauts ont pour motif DebtCon mais cette modalité est probablement aussi la plus fréquente dans l'ensemble des prêts. Il faudrait donc comparer les taux de défaut par modalité (DebtCon et HomeImp) avant de conclure. Pour JOB, la catégorie Other regroupe beaucoup de cas, mais elle est aussi très représentée dans les données.



Ce qui a changé entre les modèles : Le taux de mauvaise classification varie, et l'utilisation des variables change radicalement. L'arbre de décision s'appuie presque exclusivement sur la variable IM_DEBTINC, tandis que la Forêt et le Réseau de neurones répartissent l'importance sur d'autres variables comme DEROG et VALUE.

Les modèles complexes sont-ils meilleurs ? Non le modèle le plus simple (l'arbre de décision) est le gagnant : il présente le taux de mauvaise classification le plus bas (la barre bleue la plus petite) et la meilleure matrice de confusion.

Pourquoi les modèles simples gagnent parfois : Les modèles complexes (comme les réseaux de neurones) nécessitent souvent des jeux de données massifs et un réglage très précis des hyperparamètres. Sans cela, ils ont tendance à faire du "surapprentissage" sur le bruit des données, là où un modèle simple capture directement les signaux les plus évidents avec robustesse.

Task 3a: Using SAS Viya Copilot to Improve your Visual Analytics Project

Questions posées à Copilot et analyse des réponses :

Do you see any current weaknesses in my analysis?

Surapprentissage : Non Copilot ne fait aucune mention du surapprentissage.

Stratégie de validation : Pas directement, mais il mentionne un problème majeur dans la validation : la taille des échantillons diffère selon les modèles ce qui biaise la comparaison.

Prédicteurs supplémentaires : Non

Problèmes d'interprétabilité : Oui il indique que les couches tronquées du réseau de neurones peuvent nuire à l'interprétabilité.

Can you summarize my report in a couple of paragraphs?

Précision technique : Oui, le résumé décrit correctement la structure globale du rapport, les données utilisées (_PREPPED) et les types de modèles testés

Identification du modèle champion : Non.

Rôle de IM_DEBTINC : Non.

Prêt pour un décideur ? Non il ne faut pas l'envoyer tel quel. Ce résumé décrit en fait la liste des graphiques au lieu d'en donner les conclusions métier.

Can you describe the outcomes of the modeling, including which model is best and which factors were most influential?

Identification du modèle champion : Non Copilot échoue à identifier le modèle gagnant. Au lieu de désigner l'Arbre de décision, il suppose que la Random Forest et le Réseau de neurones sont probablement les plus performants.
Classement précis des variables : Non. Il fait une liste des variables (DELINQ, DEROG, IM_DEBTINC, etc.) sans fournir le classement de leur importance relative.
Distinction entre corrélation et causalité : Non.

Are there additional models I should explore in my predictive modeling?
Régression logistique : Oui

Gradient boosting : Oui

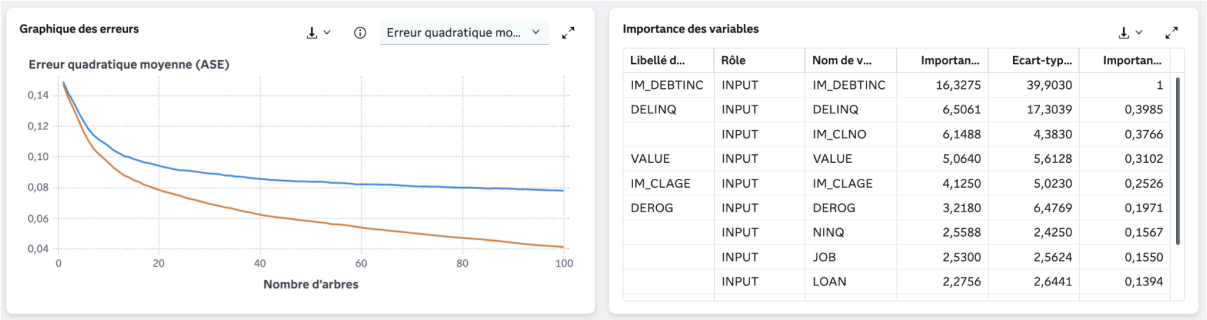
Modèles régularisés : Non

Stratégies de validation alternatives : Non

When does it make sense to run a gradient boosting model?

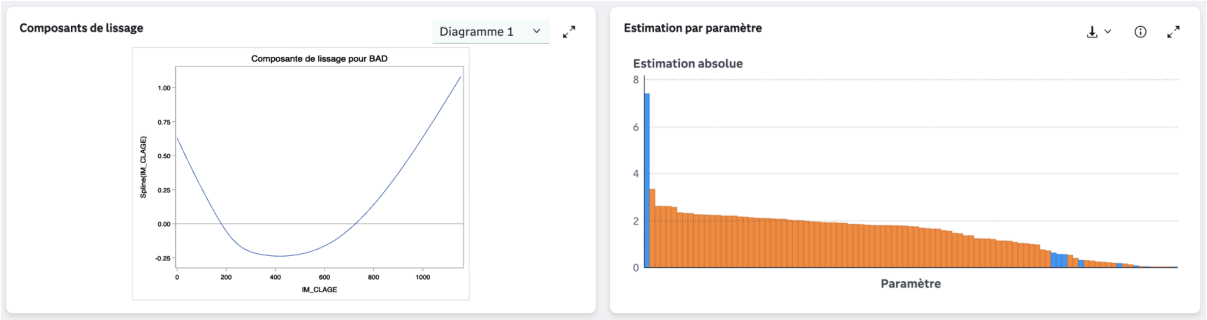
Taille du jeu de données : Pas abordé
Effets non linéaires : Oui Copilot identifie que le modèle est idéal pour capturer des relations complexes et non linéaires.
Précision vs Explication : Oui Copilot indique que l'objectif principal de ce choix est d'obtenir une haute accuracy
Interprétabilité et contexte réglementaire : pas vraiment, il mentionne que le modèle fournit l'importance des variables mais ce modèle reste une boîte noire.

Task 4: Going Deeper with SAS Model Studio



Libellé d...	Rôle	Nom de v...	Importan...	Ecart-typ...	Importan...
IM_DEBTINC	INPUT	IM_DEBTINC	16,3275	39,9030	1
DELINQ	INPUT	DELINQ	6,5061	17,3039	0,3985
	INPUT	IM_CLNO	6,1488	4,3830	0,3766
VALUE	INPUT	VALUE	5,0640	5,6128	0,3102
IM_CLAGE	INPUT	IM_CLAGE	4,1250	5,0230	0,2526
DEROG	INPUT	DEROG	3,2180	6,4769	0,1971
	INPUT	NINQ	2,5588	2,4250	0,1567
	INPUT	JOB	2,5300	2,5624	0,1550
	INPUT	LOAN	2,2756	2,6441	0,1394

Graphique des erreurs : L'erreur quadratique moyenne diminue au fil de l'ajout d'arbres. L'écart qui se creuse entre la courbe inférieure et la courbe supérieure montre le phénomène de surapprentissage classique à mesure que le modèle se complexifie.
Importance des variables : La variable IM_DEBTINC domine les décisions du modèle, avec une importance relative maximale de 1. Les variables suivantes, DELINQ (0,3985) et IM_CLNO (0,3766) ont un poids beaucoup plus faible dans les prédictions.



Composante de lissage : Le modèle GAM montre l'effet non linéaire de la variable IM_CLAGE sur BAD. La courbe en U indique que le risque est plus élevé pour les valeurs très faibles, diminue pour les valeurs moyennes, puis réaugmente pour les valeurs très élevées (au-delà de 700).

Estimation par paramètre : Le diagramme montre l'importance absolue des différents paramètres du modèle. Un paramètre spécifique domine très largement les prédictions avec une estimation absolue autour de 7,5 alors que l'influence de tous les autres paramètres est beaucoup plus faible, plafonnant en dessous de 3.5 et décroissant.

Cham...	Nom	Nom de ...	KS (You...	Exactitu...	Erreur q...	Zone so...	Lift cum...	Pourcen...	Seuil	Rôle de ...	Profond...	Score F1
★	Gradient Boosting	Gradient Boosting	0,7090	0,8898	0,0780	0,9296	4,4818	44,8179	0,5000	VALIDATE	10	0,6878
	Arbre de décision	Arbre de décision	0,6018	0,8658	0,1005	0,8561	3,9037	39,0370	0,5000	VALIDATE	10	0,6562
	GAM	GAM	0,4226	0,8350	0,1242	0,7946	3,4734	34,7339	0,5000	VALIDATE	10	0,3400

Le modèle Gradient Boosting est désigné champion car il surpasse l'arbre de décision et le GAM sur la plupart des métriques de validation affichées avec le meilleur score KS (0,7090) et la plus faible erreur quadratique (0,0780).

Cham...	Nom	Nom de ...	KS (You...	Exactitu...	Erreur q...	Zone so...	Lift cum...	Pourcen...	Seuil	Rôle de ...	Profond...	Score F1
★	Gradient Boosting	Gradient Boosting	0,7286	0,8971	0,0752	0,9327	4,3978	43,9776	0,5000	VALIDATE	10	0,7160
	Ensemble	Ensemble	0,6929	0,8926	0,0832	0,9186	4,3137	43,1373	0,5000	VALIDATE	10	0,6943
	Réseau de neurones	Réseau de neurones	0,4515	0,8277	0,1290	0,7720	3,3053	33,0532	0,5000	VALIDATE	10	0,3765
	Forêt	Forêt	0,7090	0,8881	0,0805	0,9215	4,4818	44,8179	0,5000	VALIDATE	10	0,6904
	Régression logistique ascendante	Régression logistique	0,6404	0,8652	0,0952	0,8729	4,1176	41,1765	0,5000	VALIDATE	10	0,6181
	Régression logistique pas à pas	Régression logistique	0,6404	0,8652	0,0952	0,8729	4,1176	41,1765	0,5000	VALIDATE	10	0,6181
	Arbre de décision	Arbre de décision	0,6473	0,8775	0,0933	0,8427	4,2857	42,8571	0,5000	VALIDATE	10	0,6858

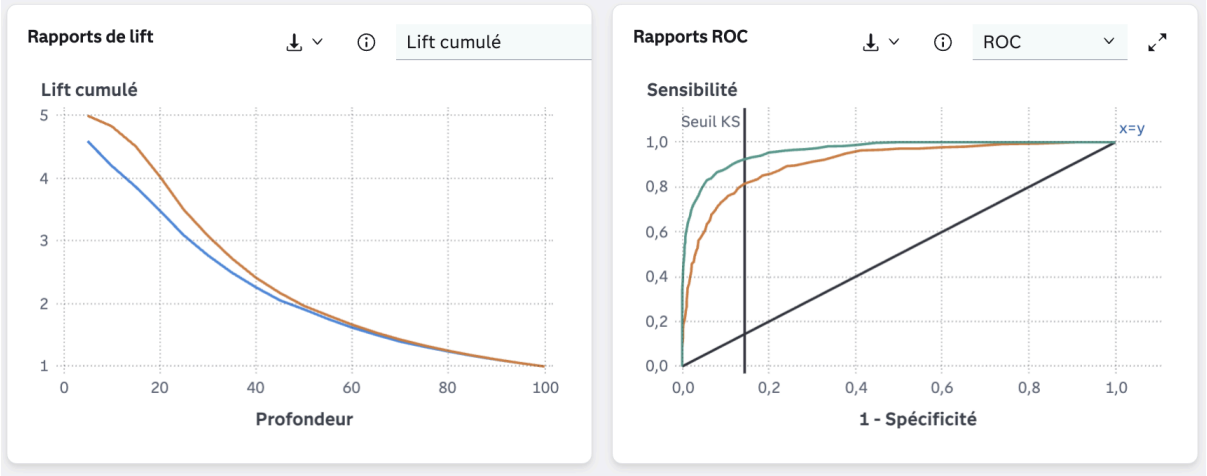
Le modèle Gradient Boosting est désigné champion car il affiche les meilleures performances sur les données de validation, avec le score KS le plus élevé (0,7286), la meilleure exactitude (0,8971) et la plus faible erreur quadratique (0,0752). Les modèles Forêt et Ensemble sont proches mais le Réseau de neurones a les moins bons résultats globaux.

rpt_var_imp.csv

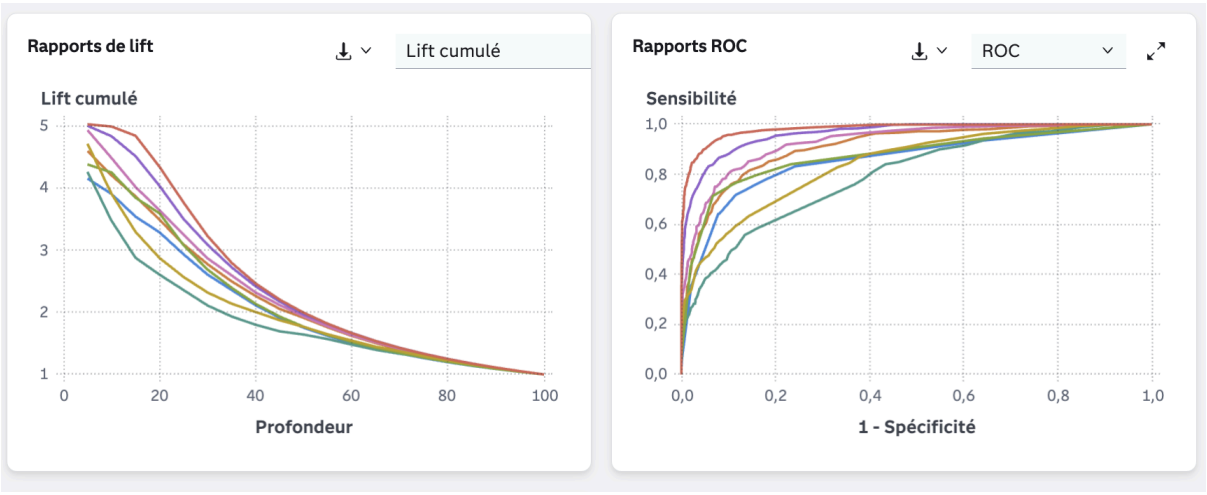
Variable Name	↓ Importance d'apprenti...
IM_DEBTINC	0,3230
IM_CLAGE	0,1012
LOAN	0,0945
IMP_VALUE	0,0696
IM_MORTDUE	0,0600
IMP_DELINQ_3	0,0302
IMP_DELINQ_2	0,0280
IMP_DEROG_1	0,0273
IMP_DELINQ_1	0,0268

Les résultats du modèle Python Random Forest intégré confirment que IM_DEBTINC est la variable prédictive la plus importante avec un score de 0,3230.

Passage de la forêt aléatoire à l'apprentissage supervisé :



L'évaluation du modèle Python Forest confirme sa très bonne capacité prédictive avec des courbes ROC s'élevant rapidement au-dessus de la ligne aléatoire



Les graphiques de Lift cumulé et ROC comparent la capacité prédictive de plusieurs algorithmes, révélant que le gradient boosting (la courbe supérieure) surpasse les autres en termes de sensibilité et de ciblage précoce.

Synthèse du projet

Le modèle champion pour ce projet est Gradient Boosting à partir du pipeline “Advanced Template”. Le modèle a été choisi sur la base de KS (Youden) pour la partition Valider (0,73). 89,71% de la partition Valider a été correctement classé en utilisant le modèle Gradient Boosting. Les cinq facteurs les plus importants sont DEBTINC, DELINQ, VALUE, CLAGE et CLNO.

Variable à expliquer du projet:	BAD	**Champion du projet:**	Gradient Boosting
Pourcentage d’événements:	19,9497 %	**Créé par:**	mathura.santhalingam@edu.univ-paris13.fr
Pipelines:	2	**Modifié:**	30 octobre 2026, 09:20:41

Task 4a: Using Copilot to Improve and Interpret your SAS Model

Questions posées à copilot et analyse des réponses :

Do you see any potential weaknesses in my current modeling what pipeline?
Déséquilibre des classes : Oui abordé dans la section Sparse Target Variables avec une recommandation d'utiliser des techniques de suréchantillonnage.

Risque de surapprentissage : Oui

Ingénierie des caractéristiques : Oui copilot souligne le besoin d'enrichir, transformer ou extraire des caractéristiques pour pallier les faiblesses des données brutes.

Stratégie de validation : Oui il suggère d'utiliser des ensembles de validation, la validation croisée et des partitions de test pour évaluer la généralisation.

Conclusion : Copilot a identifié des problèmes techniques liés aux données mais il a pas parlé des enjeux métier pour le crédit immobilier

How could I improve the performance of my current champion model?
Suggestions abordées : Copilot recommande l'optimisation des hyperparamètres l'ingénierie des caractéristiques et la validation croisée

Réalisme métier : L'ingénierie des caractéristiques et la validation croisée permettent de consolider les performances du modèle tout en s'appuyant sur des données transparentes

Risques et baisse d'interprétabilité : Le recours massif à l'optimisation automatique des hyperparamètres augmente le risque de surapprentissage

What trade-offs should I consider when choosing this model in a mortgage lending scenario?
Interprétabilité vs Précision : Oui il souligne ce compromis, notant que la recherche d'une grande précision se fait souvent au détriment de l'explicabilité.

Explicabilité réglementaire : Oui, il insiste beaucoup sur ce point rappelant que la conformité exige de pouvoir justifier les décisions de crédit.

Risque d'équité : Oui il mentionne explicitement le risque que le modèle reproduise des inégalités historiques présentes dans les données et recommande des évaluations d'équité

Stabilité dans le temps : Non.

What should I consider when deploying and monitoring this model?

Drift detection : Oui Copilot identifie comme une cause de dégradation des performances nécessitant une action.

Performance monitoring : Oui, il recommande d'utiliser les outils de comparaison des pipelines pour surveiller en continu l'évolution des statistiques d'évaluation

Periodic retraining : Oui, il conseille de mettre en place une stratégie de réentraînement utilisant des données mises à jour dès que les performances du modèle déclinent.

Fairness evaluation : Non

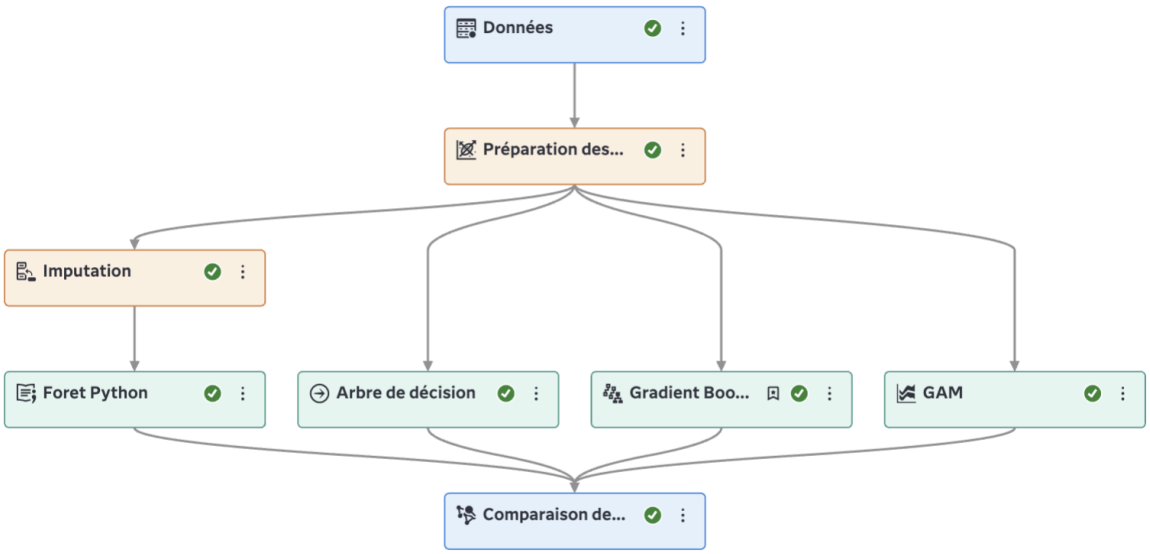
Conclusion task 4 :

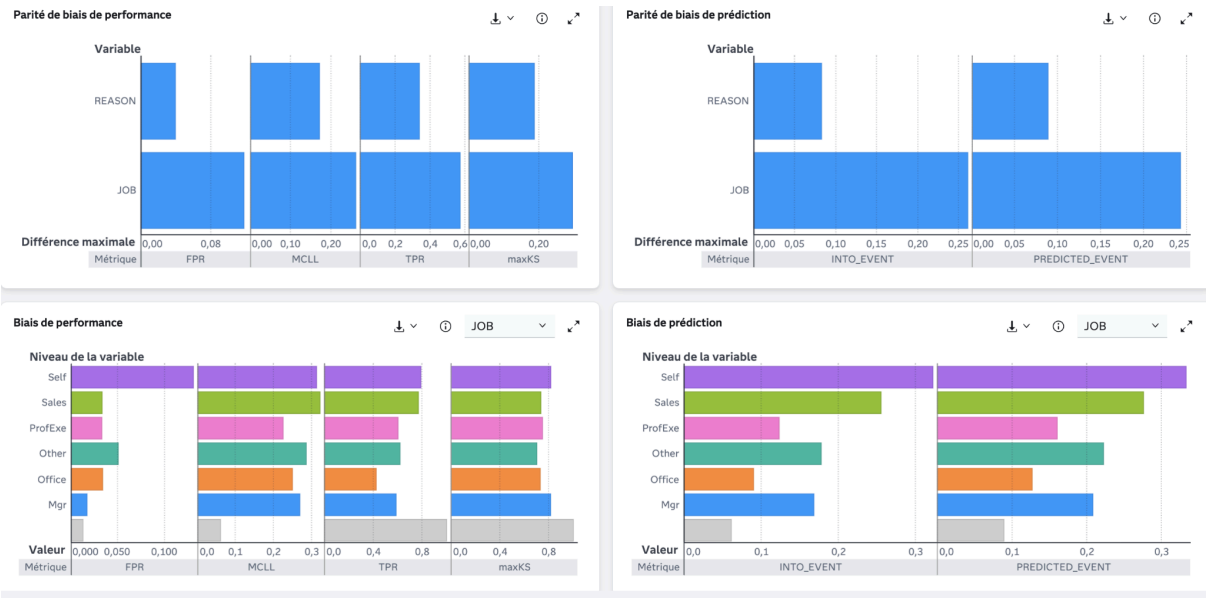
Copilot vient enrichir et sécuriser l'approche en suggérant des pistes d'optimisation, en soulignant les risques de biais ou de conformité et en stimulant une réflexion critique sur la gouvernance.

Task 5: Adding Ethical Data Analysis to your SAS Model Studio Project

L'équité par la simple suppression des variables sensibles est inefficace car d'autres caractéristiques peuvent agir comme des proxys discriminants. Il faut plutôt adopter l'équité par la mesure en utilisant des outils comme l'option "Évaluer le biais" pour auditer activement le modèle et prouver statistiquement son impartialité.

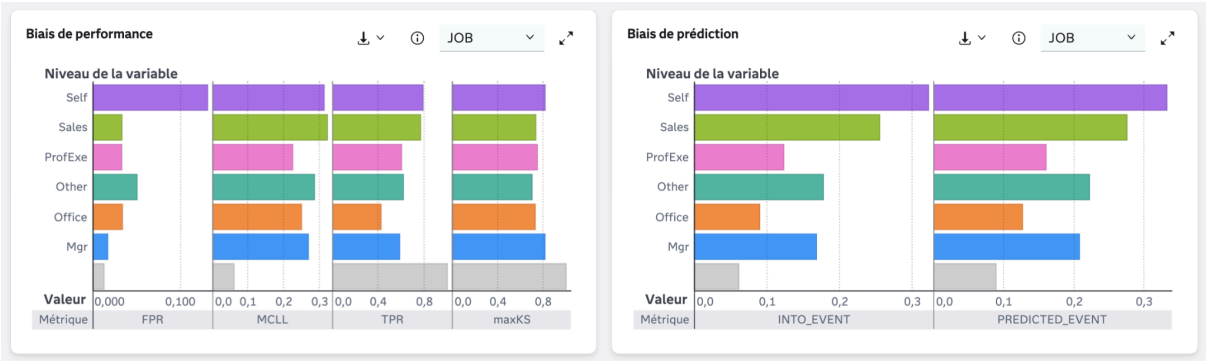
On a choisi JOB et REASON comme évaluation biais et gradient boosting est toujours le champion.

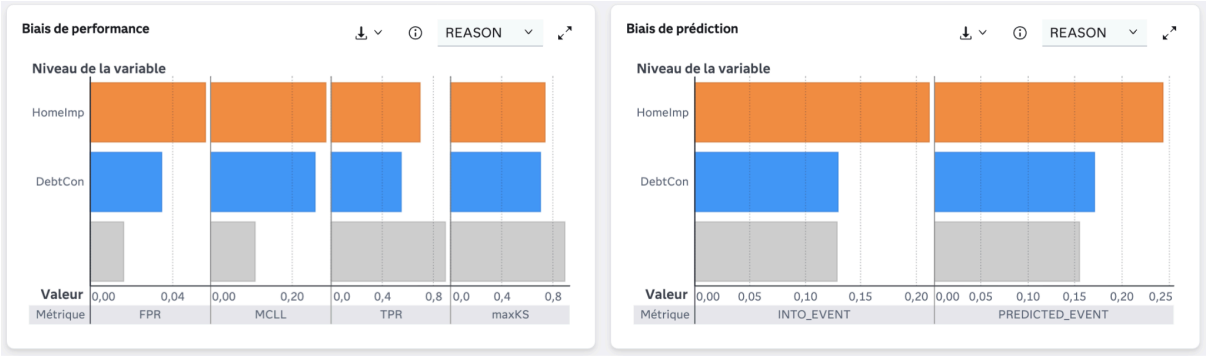




Les graphiques d'évaluation révèlent que la variable JOB génère de fortes disparités de prédiction et de taux d'erreur entre les différentes catégories professionnelles.

En gros, même si la profession peut être un indicateur de risque lié à la stabilité des revenus, elle risque d'agir comme un proxy. L'utilisation d'un modèle s'appuyant sur un proxy discriminatoire pour refuser des prêts enfreint les réglementations strictes sur l'équité bancaire (Fair Lending) donc exposant l'institution à des sanctions



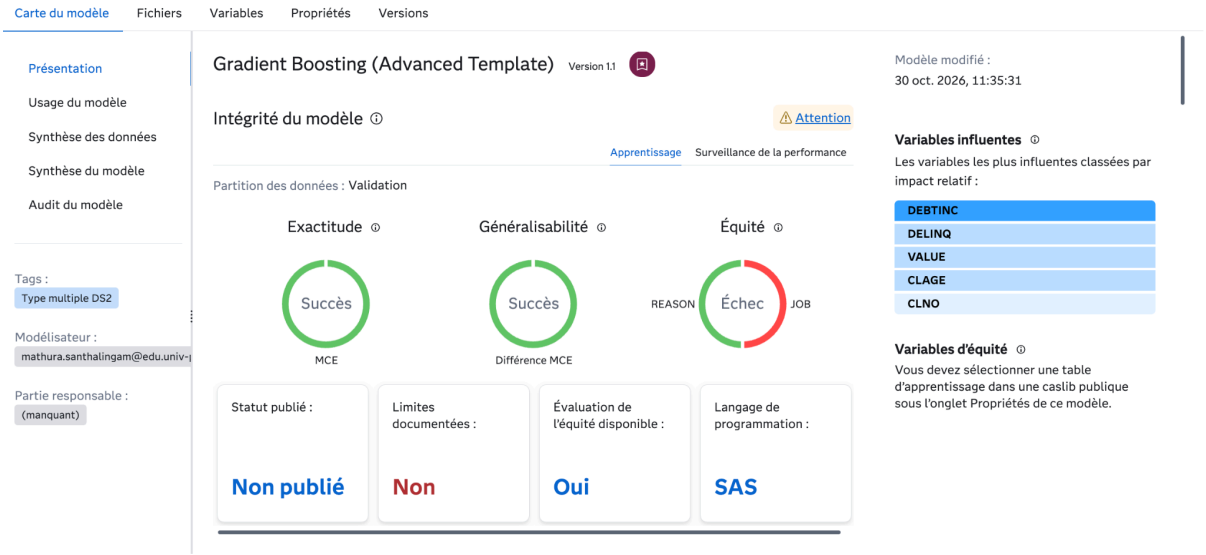


Les graphiques montrent que la variable JOB présente des écarts majeurs de performance et de prédiction selon les catégories professionnelles alors que les variations de REASON sont moins marquées que pour JOB.

Donc pour créer un processus d'octroi de prêt plus équitable et moins risqué sur le plan de la conformité,exclure JOB est une piste, suivie d'une nouvelle évaluation du biais car d'autres variables peuvent jouer le rôle de proxy.

Task 6: Reviewing the Champion Model with SAS Model Manager

Carte du modele Gradient Boosting



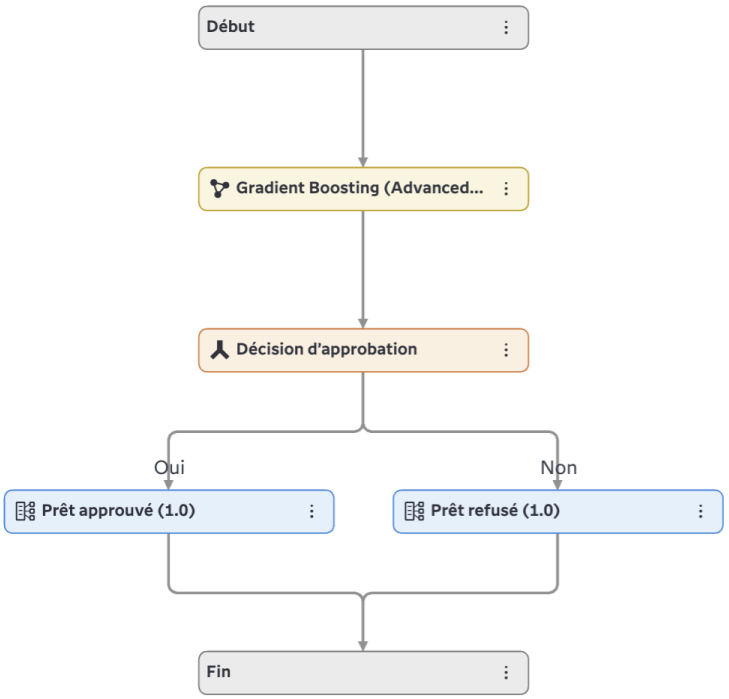
Exactitude et Généralisabilité : Les deux indicateurs affichent un succès basé sur le MCE et la Différence MCE

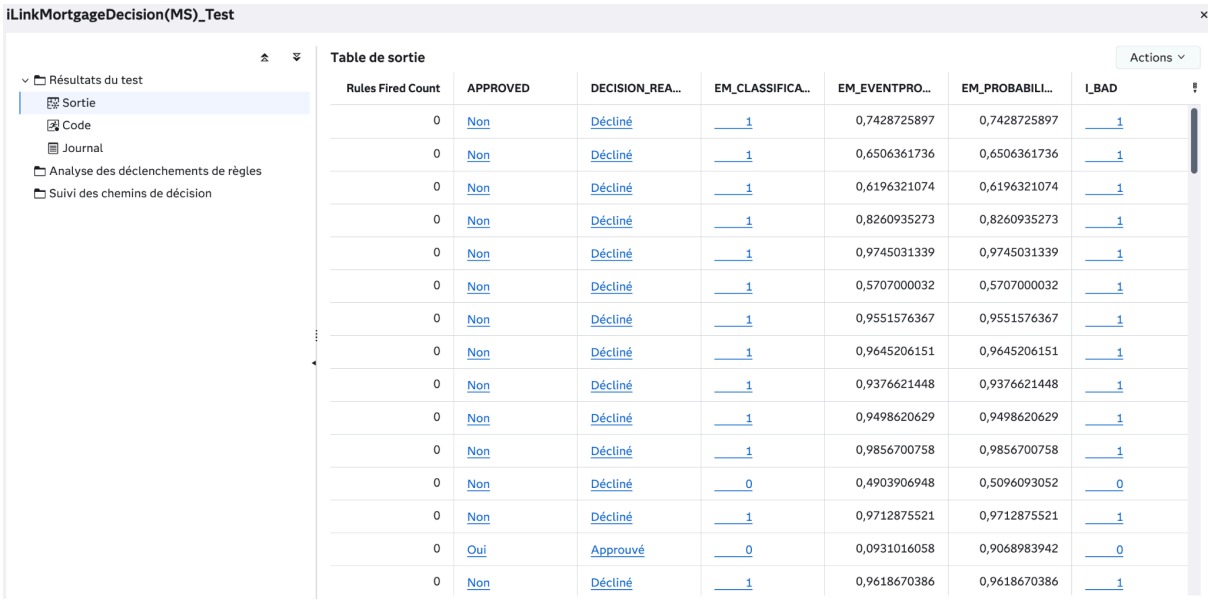
Variables influentes : DEBTINC est la plus influente, suivie de DELINQ, VALUE, CLAGE et CLNO

Alertes et Équité : Un avertissement "Attention" est visible en haut, et le test d'équité est en échec à cause des variables REASON et JOB.

Explication: les performances sont explicables aux métiers mais l'échec critique sur l'équité indique un risque de comportement discriminatoire, aggravé par l'absence totale de limites documentées.

Task 7: Scoring New Loan Applications with SAS Intelligent Decisioning





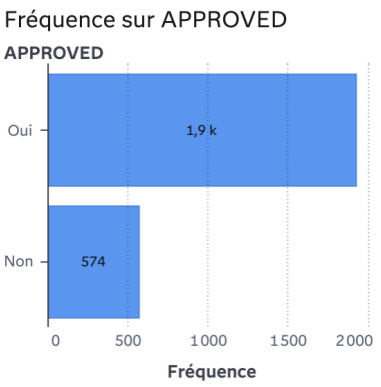
Rules Fired Count	APPROVED	DECISION_REA...	EM_CLASSIFICA...	EM_EVENTPRO...	EM_PROBABILI...	I_BAD
0	Non	Décliné	1	0,7428725897	0,7428725897	1
0	Non	Décliné	1	0,6506361736	0,6506361736	1
0	Non	Décliné	1	0,6196321074	0,6196321074	1
0	Non	Décliné	1	0,8260935273	0,8260935273	1
0	Non	Décliné	1	0,9745031339	0,9745031339	1
0	Non	Décliné	1	0,5707000032	0,5707000032	1
0	Non	Décliné	1	0,9551576367	0,9551576367	1
0	Non	Décliné	1	0,9645206151	0,9645206151	1
0	Non	Décliné	1	0,9376621448	0,9376621448	1
0	Non	Décliné	1	0,9498620629	0,9498620629	1
0	Non	Décliné	1	0,9856700758	0,9856700758	1
0	Non	Décliné	0	0,4903906948	0,5096093052	0
0	Non	Décliné	1	0,9712875521	0,9712875521	1
0	Oui	Approuvé	0	0,0931016058	0,9068983942	0
0	Non	Décliné	1	0,9618670386	0,9618670386	1

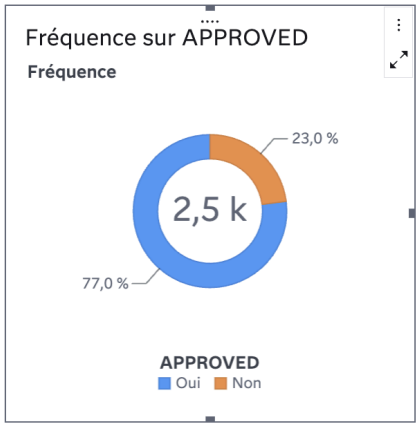
On voit la présence des nouvelles variables de décision APPROVED et DECISION_REASON associées aux sorties prédictives du modèle comme EM_EVENTPROBABILITY et EM_CLASSIFICATION.

Task 8: Return to SAS Visual Analytics to Review New Loan Decisions

574 refus et le donut indique 77 % d'approbation pour un total d'environ 2,5 k demandes, donc environ 1 920 approbations

Filtres : Aucune sélection





Application_ID ▲	APPROVED	DECISION_REASON	EM_CLASSIFICATION	JOB	EM_EVENTPROBABILITY	EM_P
1	Non	Décliné	1	Other	0,7428725897	0
2	Non	Décliné	1		0,6506361736	0
3	Non	Décliné	1	Office	0,6196321074	0
4	Non	Décliné	1	Other	0,8260935273	0
5	Non	Décliné	1	Other	0,9745031339	0
6	Non	Décliné	1	Sales	0,5707000032	0
7	Non	Décliné	1	Mgr	0,9551576367	0
8	Non	Décliné	1	Other	0,9645206151	0
9	Non	Décliné	1	Other	0,9376621448	0
10	Non	Décliné	1	Mgr	0,9498620629	0
11	Non	Décliné	1	Mgr	0,9856700758	0
12	Non	Décliné	0	Mgr	0,4903906948	0
13	Non	Décliné	1	Other	0,9712875521	0
14	Oui	Approuvé	0	ProfExe	0,0931016058	0
15	Non	Décliné	1	Other	0,9618670386	0
16	Non	Décliné	1	ProfExe	0,727486329	
17	Oui	Approuvé	0	Office	0,0778057886	0
18	Oui	Approuvé	0	Office	0,1068594987	0
19	Non	Décliné	1	Other	0,9624798201	0
20	Non	Décliné	0	Other	0,4386021591	0
21	Non	Décliné	1	Other	0,8920355881	0
22	Non	Décliné	1	Mgr	0,9691252053	0
23	Non	Décliné	1	Other	0,5251320629	0
24	Oui	Approuvé	0	Mgr	0,0790297825	0
25	Non	Décliné	1	Office	0,9524977605	0

Which new loan applications were approved?

Les nouvelles demandes de prêt qui ont été approuvées correspondent à Application_ID 14, 17, 18 et 24.

What percentage of new loan applications were approved?

77 % des demandes de prêt ont été approuvées

Does that approval rate seem reasonable for a mortgage lending business?

77 % peut sembler élevé mais ça dépend des objectifs de croissance de l'établissement et de la qualité globale des dossiers

Are any approved loans surprising?

Aucun prêt approuvé visible n'est surprenant : leurs probabilités sont toutes inférieures à 0,11.

Do any approved loans have a relatively high model-estimated probability of default?
Non parmi les prêts approuvés visibles, les probabilités de défaut sont faibles : ID 14 = 0,093 ; ID 17 = 0,078 ; ID 18 = 0,107 ; ID 24 = 0,079.

Were some loans approved because of the business rule rather than the model score alone?
Non Rules Fired Count = 0 pour toutes les observations, y compris les prêts approuvés. La décision vient donc du seuil appliqué à la probabilité du modèle pas d'une règle métier.

If you were responsible for portfolio risk, would you be comfortable with these approvals?
Oui concernant les dossiers individuels visibles car leur probabilité de défaut estimée est très faible. Mais le taux d'approbation global élevé de 77 % nécessite une surveillance pour garantir que l'exposition totale au risque reste dans les limites acceptables

If you were responsible for customer access and fairness, would you be comfortable with these declines?
Non car l'utilisation de variables potentiellement porteuses de biais historiques (comme la variable JOB) fait douter de l'équité du modèle. Il y a un risque que les refus affectent de manière disproportionnée certains groupes démographiques.

What would you want to investigate before using this decision flow again?
Il faudrait analyser l'impact des variables sensibles pour s'assurer que le modèle est équitable auditer les raisons précises des 23 % de refus ou encore introduire des règles métier correctives pour garantir l'équité des décisions avant une mise en production.